Recommendation System for Ecommerce Implicit Data

Team 3 | 박세은, 손현경, 전지윤

Motivation

기존 대부분의 추천 시스템 모델은 explicit feedback(e.g., ratings, like/unlike)에 기반해 개발되어 왔다. 그러나 실제 대부분의 서비스에서 수집되는 사용자의 데이터는 implicit feedback(e.g., user event session logs)이다.

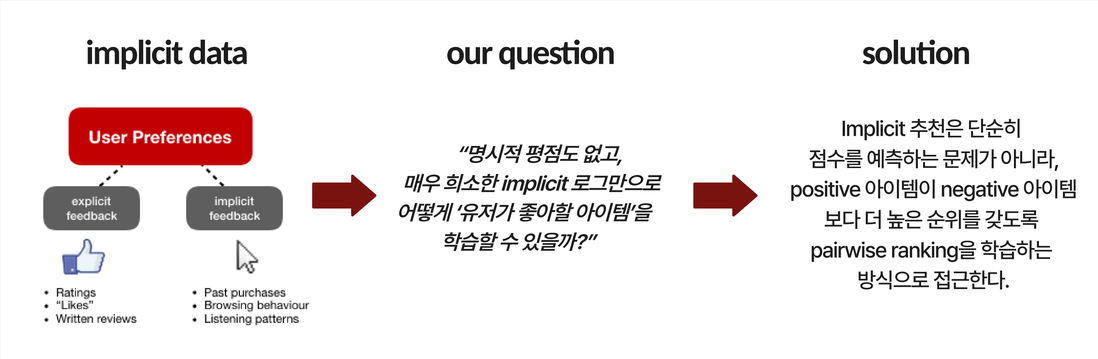

Dataset

Kaggle: Ecommerce Behavior Data from Multi-category Store (2019/10)
Behavior data from a large multi-category online store.

Property	Description
event_time	Time when event happened at (in UTC).
event_type	Three kinds of events: view, cart and purchase.
product_id	ID of a product
category_id	Product's category ID
category_code	Product's category taxonomy (code name) if it was possible to make it. Usually present for meaningful categories and skipped for different kinds of accessories.
brand	Downcased string of brand name. Can be missed.
price	Float price of a product. Present.
user_id	Permanent user ID.
** user_session**	Temporary user's session ID. Same for each user's session. Is changed every time user come back to online store from a long pause.

Implicit Feedback 구성	
view	약한 positive
cart	중간 positive
purchase	강한 positive

Preprocessing

Preprocessing 과정에서는 우선 brand 정보를 category 형태로 변환하고, 일부 존재하던 brand 결측치는 제거하였다. 이후 사용자–아이템 간 상호작용을 구성하였으며, 이 과정에서 전체 데이터의 희소성이 99.98%에 달하는 매우 sparse한 user–item interaction matrix가 생성되었다.

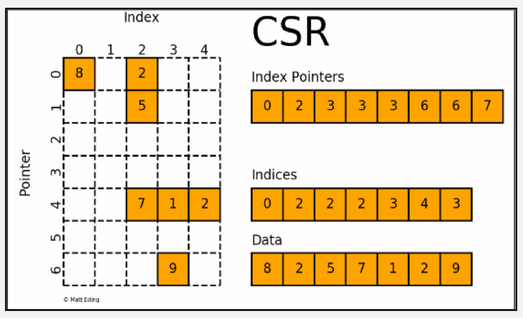

Sparse Matrix는 다음 절차로 구축하였다. 먼저 user_id와 product_id를 각각 인덱스로 인코딩하고, implicit feedback을 기반으로 positive는 1, negative는 0으로 구성하였다. 이후 생성된 데이터는 COO 형식으로 만든 뒤, 효율적인 연산을 위해 CSR 포맷으로 변환하였다.

EDA

1. 결측치 확인

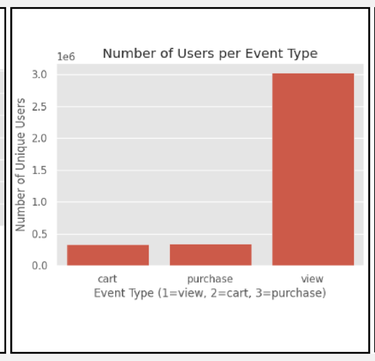

2. 이벤트별 유저 분포

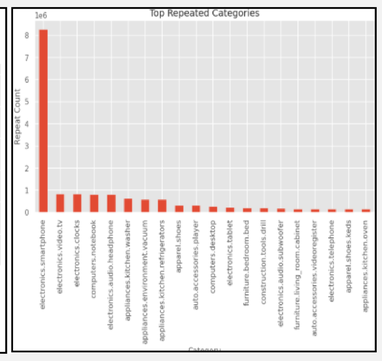

3. 카테고리 기준 재구매 분포

Train

1. Implicit user–item interaction 을 기반으로 CSR matrix 구성
2. event_time 기준 정렬 후 시간 기반 Train/Test Split
3. LightFM(WARP loss) 로 모델 학습 (epochs = 30)
4. 예측 시, Train 데이터에 등장한 product는 제외하여 신규 상품에 대한 순위 산출

Evaluation

(1) Offline Evaluation

"We do not care about the actual score values. What matters is whether the model ranks positive items higher than negative items."

Offline evaluation의 핵심 목표는 모델이 positive item을 negative item보다 더 높은 순위에 배치하는지를 확인하는 것이다. 즉, 중요한 것은 점수의 절대값이 아니라 순위(ranking) 품질이며, 이를 평가하기 위해 주로 AUC, NDCG@K 등의 지표를 사용한다.

Models Comparsion

(1) ALS (Alternating Least Squares): collaborative filtering의 대표적인 행렬 분해 기반 알고리즘으로 implicit feedback 데이터를 처리할 수 있는 버전을 제공한다
(2) BPR (Bayesian Personalized Ranking): LightFM 모델에서 loss function을 BPR로 설정하여 적용할 수 있다.

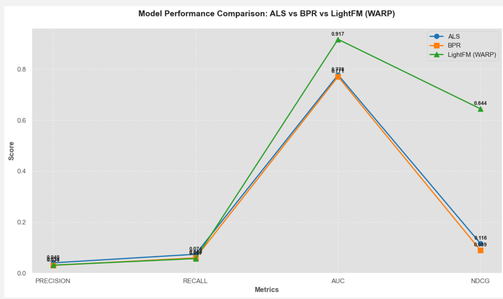

Model	AUC	NDCG @10	Precision@10	Recall @10
LightFM (WARP)	0.9172	0.6444	0.0311	0.0570
BPR	0.7706	0.0890	0.0303	0.05964
ALS	0.7778	0.1155	0.0403	0.07390

epoch = 20, user = 50,000

Hyperparameter Tuning (Optuna)

자동 최적화 프레임워크인 Optuna를 활용하여 진행하였다. 총 5회의 trials를 수행하며 모델 성능을 기준으로 최적의 하이퍼파라미터 조합을 탐색하였다.

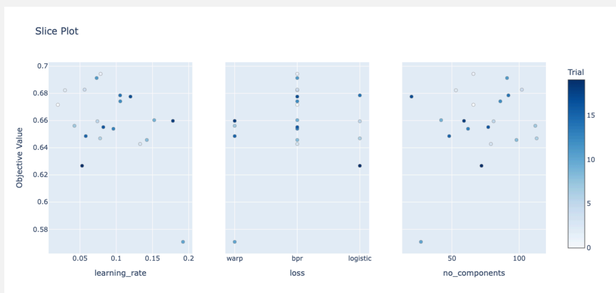

params	value
no_components	32
learning_rate	0.075
loss	bpr

Best NDCG: 0.67293

(2) Online Evaluation - Real Service

실제 서비스의 평가 방식 : 모델의 추천 상품을 유저가 실제 클릭했는가

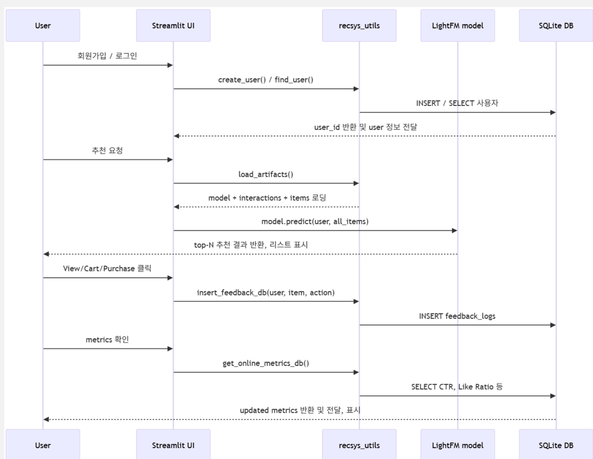

Streamlit과 SQLite를 활용해 유저 인터랙션 페이지를 구현하고 클릭률 계산

Conclusion

본 연구는 실제 서비스 환경에서 얻는 sparse하고 noisy한 implicit feedback 기반의 e-commerce 추천 문제를 해결하고자, 점수 예측이 아닌 positive 아이템이 negative 아이템보다 높은 순위를 갖도록 pairwise ranking을 학습하는 접근을 적용하였다.
Offline evaluation을 위해 ALS, BPR, LightFM 모델을 비교한 결과, LightFM이 NDCG@10은 0.6444, AUC는 0.9172로 가장 우수한 성능을 보였다.
또한, online evaluation를 함께 적용해 실제 서비스에 근접한 검증을 수행하였다.

References

[1] Maciej Kula et al. "Model evaluation." In LightFM documentation. Available: https://making.lyst.com/lightfm/docs/lightfm.evaluation.html
[2] "10 metrics to evaluate recommender and ranking systems." Evidently AI guide, updated February 14, 2025. https://www.evidentlyai.com/ranking-metrics/evaluating-recommender-systems
[3] Aryan Jadon and Avinash Patil. A Comprehensive Survey of Evaluation Techniques for Recommendation Systems. (preprint / book chapter). Springer, 2024. DOI: 10.1007/978-3-031-71484-9_25
[4] Ethan Rosenthal. "Learning to Rank Sketchfab Models with LightFM." Blog post, November 7, 2016. https://www.ethanrosenthal.com/2016/11/07/implicit-mf-part-2/